

CANALES SIN RUIDO. CÓDIGOS COMPRESORES

SI EL CANAL POR EL QUE CIRCULA LA INFORMACIÓN NO ES ALTERADO POR RUIDO, NUESTRO PROPÓSITO EN LA CODIFICACIÓN SERÁ REDUCIR LOS MENSAJES A SU FORMA MÁS CONCISA POSIBLE

¿CODIFICACIÓN SIN COMPRIMIR DE $A = \{a, b, \dots, x, y, z\}$?
UN VECTOR DE BITS LONGITUD 5 ($2^4 = 16 \leq 27 \leq 2^5 = 32$)

¿CÓDIGOS PARA COMPRIMIR?

↳ DE LONGITUD VARIABLE CON DESCODIFICACIÓN ÚNICA
SIMBOLOS MÁS FRECUENTES \rightarrow MENOR LONGITUD
SIMBOLOS MENOS FRECUENTES \rightarrow MAYOR LONGITUD

DESCODIFICACIÓN ÚNICA

PARA QUE EL CÓDIGO SEA ÚTIL DEBE TENER DESCODIFICACIÓN ÚNICA. PROBLEMA: LONGITUD VARIABLE ¿DONDE EMPIEZA Y TERMINA CADA PALABRA?

EJ: SI CODIFICAMOS $A = \{a, b, c\}$ ASÍ

FUENTE	CODIFICACIÓN
a	0
b	1
c	01

(a ES PREFIJO
DE c, NO ES
INSTANTANEO)

¿COMO DECODIFICAMOS 0101?

cc / cab / abc / abab

NO ES ÚNICA → NO NOS VALE

SOLUCIONES:

- USAR UN SÍMBOLO SEPARADOR (COMO EN CÓDIGO MORSE)
PERO NO ES UNA BUENA IDEA. SE PIERDE EFICIENCIA
- USAR UN CÓDIGO INSTANTANEO (PREFIX CODE)

DEF: DECIMOS QUE UN CÓDIGO ES INSTANTANEO SI NINGUNA PALABRA CÓDIGO ES PREFIJO DE LA OTRA

EJ: SI EL ALFABETO FUENTE ES $A = \{a, b, c\}$ Y LA FRECUENCIA CON QUE APARECE a ES MAYOR QUE b Y c . PODEMOS CODIFICAR A COMO

FUENTE	COD I	COD II
a	0	0
b	01	10
c	11	11

↑
NO

INSTANTANEO

↑

INSTANTANEO

AUNQUE TENGA,
DESCODIFICACIÓN ÚNICA

EJ : 01111.....

COD I:

DEPENDE DEL
FINAL

< a c - - - - - c
b c - - - - - c

0 1 1 1 1 1 a c c c
0 1 1 1 1 b c c

Y TENEMOS QUE ESPERAR

NO ES ÚTIL ESPERAR TANTO

COD II:

0 1 1 1 c - - -
a c c

Th : TODO CÓDIGO INSTANTÁNEO TIENE DESCODIFICACIÓN
ÚNICA.

⊄ NO, ES CIERTO ES COD I, TIENE DESCODIFICACIÓN
ÚNICA PERO NO ES INSTANTÁNEO

LONGITUD MEDIA DE UN CÓDIGO

J = FUENTE ASOCIADA AL ALFABETO $A = \{a_1, \dots, a_m\}$
CON DISTRIBUCIONES DE PROBABILIDAD p_1, \dots, p_m
 $p_1 + \dots + p_m = 1$

SEA C UN CÓDIGO q -ARIO DE J DONDE LAS
LONGITUDES DE LAS PALABRAS DE C SON l_1, \dots, l_m

(a_i APARECE CON PROBABILIDAD p_i Y SE CODIFICA EN UNA
PALABRA DE LONGITUD l_i)

DEF: LONGITUD MEDIA DE C

$$l(C) = \sum_{i=1}^m p_i l_i$$

ES: MENSAJE DE n SÍMBOLOS SE CODIFICA EN
 $n \cdot l(C)$ SÍMBOLOS DE MEDIA

TEOREMAS SHANNON

Th
$$l(c) \geq \frac{H(F)}{\log q}$$

← FUNCIÓN ENTROPÍA:

$$H(F) = \sum_{i=1}^m p_i \log\left(\frac{1}{p_i}\right)$$

DEF $l_q(F)$ MENOR LONGITUD MEDIA POSIBLE DE
UN CÓDIGO INSTANTANEO q -ARIO DE LA FUENTE F

Th
$$\frac{H(F)}{\log q} \leq l_q(F) \leq \frac{H(F)}{\log q} + 1$$


$$\log = \log_2$$

UNA CONSTRUCCIÓN ÓPTIMA: CÓDIGO HUFFMAN

VAMOS A REPRESENTAR EL CÓDIGO USANDO ÁRBOLES (GRAFOS)

$A = \{e, a, t, h, s\}$

EJ:



$e \mapsto 0$

$a \mapsto 10$

$t \mapsto 110$

$h \mapsto 1110$

$s \mapsto 1111$

EJ: 11111011100

CÓDIGO INSTANTÁNEO

INPUT ALGORITMO: FRECUENCIA DE CADA SÍMBOLO

OUTPUT: CODIGO COMPRESOR ÓPTIMO

1) UN BOSQUE DE ÁRBOLES, DONDE CADA ÁRBOL TIENE UN ÚNICO VÉRTICE (UNO POR CADA SÍMBOLO A CODIFICAR)
CADA VÉRTICE VIENE ETIQUETADO POR EL SÍMBOLO Y CADA ÁRBOL POR SU FRECUENCIA.

2) ITERATIVAMENTE, COMBINAMOS LOS DOS ÁRBOLES CON MENOR FRECUENCIA, INTRODUCIENDO UNA NUEVA RAÍZ
(PESO MAYOR \rightarrow IZQUIERDA)
(PESO MENOR \rightarrow DERECHA)

ETIQUETAMOS ARISTA IZQDA CON 0 Y LA DERECHA CON 1
ETIQUETAMOS EL NUEVO ÁRBOL CON LA SUMA DE LAS FRECUENCIAS.

EN CASO DE EMPATE ESCOGEMOS NOSOTROS

3/ EL ALGORITMO SE TERMINA CUANDO YA NO TENEMOS UN BOSQUE, SI NO UN ÁRBOL


EJ: $A = \{A, B, C, D, E, F\}$
 $P = \{0,08, 0,1, 0,12, 0,15, 0,2, 0,35\}$

- NÚMERO MEDIO BITS SIN COMPRESIÓN
3 ($4=2^2 \leq 6 \leq 2^3=8$)


A	000
B	001
C	010

- CON CÓDIGO HUFFMAN


VAMOS A VERLO



PASO 1



PASO 2






PASO 3



PASO 4

PASSO 5



PASSO 6

FINAL

A → 111

B → 110

C → 011

D → 010

E → 10

F → 00

NÚMERO MEDIO DE BITS USADOS CON HUFFMAN:

$$A = \{A, B, C, D, E, F\}$$

$$P = \{0,08, 0,1, 0,12, 0,15, 0,2, 0,35\}$$

$$L(C) = \sum_{i=1}^m p_i l_i$$

$$0,08 \cdot 3 + 0,1 \cdot 3 + 0,12 \cdot 3 + 0,15 \cdot 3 + 0,2 \cdot 2 + 0,35 \cdot 2 = 2,45 < 3$$

TEXTO DE 100 SÍMBOLOS. CON HUFFMAN VAMOS
A USAR DE MEDIA 245 BITS
SIN COMPRESIÓN USAMOS 300 BITS

Th: EL CÓDIGO DE HUFFMAN ES ÓPTIMO
(PARA CÓDIGOS BINARIOS)

SE PUEDE EXTENDER LA CONSTRUCCIÓN PARA
CÓDIGOS SOBRE \mathbb{F}_q